PENSE-BÊTE · TECHNIQUE ET COMMANDES

Manipulation de données sous Linux

06-330 PSE 25-27 3-4 Manipulation de données sous Linux - AWK, SED et Filtres — source : fiche de révision du module (gemma4, 03/11/2026)

À RETENIR

1. sed agit comme un éditeur de flux non interactif qui applique des transformations automatiques sur chaque ligne chargée dans le pattern space.
2. L'analyseur awk est spécialisé dans le traitement de données organisées en colonnes en divisant chaque enregistrement en champs.
3. Les filtres comme uniq permettent de supprimer les doublons à condition d'effectuer un tri préalable du fichier.

Philosophie et outils de manipulation

Notion	À retenir
Philosophie Unix	Enchaînement de petits outils spécialisés dans une tâche unique. Ils lisent une entrée, transforment en mémoire et produisent une sortie.
Familles d'outils	`sed` (substitutions/suppressions), `awk` (extraction/restructuration tabulaire) et les filtres (chercher/traduire). Objectif : analyser sans altérer les fichiers initiaux.

L'éditeur de flux SED

Notion	À retenir
Rôle principal	Éditeur de flux appliquant des scripts automatiquement sur chaque ligne pour corriger, supprimer ou remplacer du texte.
Fonctionnement	Charge la ligne dans le `pattern space`, applique les commandes, écrit vers la **sortie standard** puis recommence ; le `hold space` garde du texte entre deux cycles.
Ciblage par adresses	Cible par numéro d'apparition, intervalle ou expression régulière ; le symbole de **négation** permet d'exclure des lignes.
Suppression et filtrage	Permet d'imprimer exclusivement les lignes sélectionnées, de supprimer des entrées ou d'utiliser la commande pour **quitter**.
Insertion et substitution	Remplace un motif par un autre, ajoute du texte ou importe un document externe via les fonctions de lecture.

Synthèse du traitement AWK

Notion	À retenir
Logique d'analyse	Examine les fichiers en **colonnes**, divise chaque enregistrement en **champs** distincts et applique calculs/vérifications avant sortie.
Architecture globale	Trois blocs ordonnés : section initiale (**en-tête**), section centrale (**motif** sur la ligne) et section finale (**fin de fichier** pour totaux).
Variables et fonctions	Variables automatiques (**numéro de ligne**, **nombre de champs**) et fonctions natives : `length`, `substr`, `gsub`.
Contrôle et interactions	Conditions et boucles similaires au **langage C** ; écrit vers des **fichiers de sortie** ou des **processus externes**.

Synthèse des filtres de données

Notion	À retenir
Traduction et découpe	`tr` modifie les caractères (suppression/conversion) ; `cut` isole des positions figées ou des champs via un délimiteur spécifique.
Recherche et tri	`grep` repère des chaînes ou expressions régulières ; `egrep` (motifs complexes), `fgrep` (motifs stricts) ; `sort` réorganise (alphabétique, numérique, décroissant) et fusionne.
Déduplication et mise en forme	`uniq` supprime les répétitions de lignes consécutives (nécessite un tri) ; `fold` limite la longueur des lignes ; `head` et `tail` échantillonnent (début/fin).

Choix et assemblage des outils

Notion	À retenir
Choix du composant	`sed` pour la **modification rapide** de flux ; `awk` pour la **découpe en champs** et le **calcul** ; filtres standards pour **extraire**, **classer** ou **organiser**.
Assemblage modulaire	Association de programmes indépendants via des **pipes** pour créer des **chaînes de traitement** complexes (recherche, tri, nettoyage, filtrage).

Pièges et confusions

- ⚠ Confondre sed qui traite un flux continu avec ed qui réclame des commandes interactives.
- ⚠ Oublier que la fonction uniq requiert de manière stricte un tri préalable pour éliminer les lignes en double.
- ⚠ Négliger l'utilité du hold space pour sauvegarder des fragments de texte entre deux cycles de traitement.
- ⚠ Ne pas consulter la documentation officielle du projet GNU pour les règles de manipulation des textes.

Sigles et définitions

flux de texte	suite de données sous forme de journaux ou de fichiers de configuration divers
sed	éditeur de flux non interactif appliquant scrupuleusement des règles de transformation
awk	analyseur conçu pour manipuler des données organisées en colonnes
pattern space	zone de travail où sed charge le texte lu ligne par ligne
hold space	espace de mémorisation servant de stockage temporaire à sed
enregistrement	chaque ligne individuelle d'un fichier lue par l'outil de traitement awk
champ	segment obtenu après le découpage automatique d'une ligne par awk

Auto-test

1. Quel outil est spécifiquement conçu pour manipuler des données organisées en colonnes ?
2. Comment appelle-t-on l'endroit où sed charge le texte lu ligne par ligne ?
3. Quelle commande permet de modifier les caractères par suppression ou conversion ?
4. Quelle est la condition indispensable pour utiliser correctement la fonction uniq ?
5. Quels sont les trois blocs ordonnés de l'architecture globale d'awk ?

Réponses : **1.** awk · **2.** pattern space · **3.** tr · **4.** un tri préalable du fichier · **5.** section initiale, section centrale et section finale

À compléter par la fiche, le podcast et le quiz du module. Rédigé à partir de la fiche de révision ; seuils et chiffres à la date de la source.