PENSE-BÊTE · TECHNIQUE ET COMMANDES

Révolution et enjeux du Big Data

06-700 PSE 25-27 5-12 Big Data - Définition, enjeux et révolution des données — source : fiche de révision du module (gemma4, 03/11/2026)

À RETENIR

1. Le Big Data constitue une révolution technologique et organisationnelle impliquant la collecte, le stockage, le traitement et l'analyse de volumes de données massifs.
2. Les 3V qui définissent ses piliers fondamentaux sont le Volume, la Variété et la Vélocité.
3. L'écosystème Hadoop repose sur une architecture maître/esclave avec le NameNode pour les métadonnées et les DataNodes pour le stockage des blocs.

Fondements du Big Data

Notion	À retenir
Définition et évolution	Révolution transformant collecte, stockage, traitement et analyse de volumes massifs. Initiée par **Yahoo**, **Google** et **Facebook** (années **2000**) pour gérer **pétabytes** ou **exabytes**.
Limites traditionnelles	Les bases de données **SQL** et plateformes décisionnelles ne gèrent pas les volumétries colossales, les flux **temps réel** et les sources **hétérogènes** non relationnelles.
Les trois piliers (3V)	**Volume** (quantités massives), **Variété** (sources structurées **ERP/CRM** ou non structurées : emails, vidéos), **Vélocité** (fréquence élevée, parfois **temps réel**).
Culture data-driven	Passage de l'intuition aux décisions stratégiques basées sur les **faits**. Permet l'**analyse prédictive**, la **personnalisation en temps réel** et l'**optimisation industrielle**.

Sources et typologies des données

Notion	À retenir
Les cinq grandes sources	Applications professionnelles (**ERP**, **CRM**, **SCM**), Web, réseaux sociaux, mobile (**4x** plus d'appareils que PC/tablettes, **>150** interactions/jour) et IoT (capteurs).
Distinction typologies	Structurées : organisées en **tables** (**Oracle**, **MySQL**, **PostgreSQL**). Non structurées/semi-structurées : formats variés (**emails**, **images**, **vidéos**, **logs**) complexes à traiter.

Technologies et infrastructures de stockage

Notion	À retenir
NoSQL et modèles	Flexibilité supérieure au SQL (pas de schéma rigide). Modèles : **clé-valeur** (**Redis**), **colonne** (**HBase**), **document** (**MongoDB**), **graphe** (**Neo4J**).
Écosystème Hadoop	Plateforme open source. Composants : **HDFS** (stockage distribué), **MapReduce** (traitement parallèle : phase `Map` puis `Reduce`), **YARN** (gestionnaire de ressources), **Hadoop Common** (bibliothèques).
NameNode et DataNodes	Architecture maître/esclave. **NameNode** (maître) : gère métadonnées et espace de nommage. **DataNodes** (esclaves) : stockent les blocs (taille par défaut **128 Mo** sous Hadoop 2).

Spécificités techniques HDFS

64 Mo
Taille par défaut des blocs
Sous Hadoop 1

3 (en général)
Nombre de réplications
Garantit la tolérance aux pannes

Plusieurs centaines de pétaoctets
Capacité de stockage
Sur des milliers de nœuds

Innovations du traitement des données

Notion	À retenir
MapReduce	Traitement distribué sur **cluster** via deux phases : **Map** (opération par élément) et **Reduce** (agglomération). Adapté au **batch** (ex: analyse de logs).
Stockage in-memory	Utilise la **mémoire vive** ou **mémoires flash** (ex: `Memcached`, `Redis`, `Apache Spark`) pour des performances extrêmes en **temps réel**.
Streaming	Analyse des données dès leur arrivée (latence **milliseconde**) via `Apache Kafka`, `Apache Flink` ou `Spark Streaming`. Crucial pour **fraude**, **personnalisation** et **IoT**.

Opportunités et impacts sectoriels

Notion	À retenir
Optimisation et innovation	Entreprises n'analysent qu'environ **12 %** des données. L'**IoT** anticipe les pannes. La **logistique** optimise les chaînes d'approvisionnement et réduit les coûts.
Open Data et données publiques	Libération des données pour citoyens, entreprises et chercheurs. En **2011**, la Commission européenne estimait un CA **potentiel** de **27 milliards d'euros** par an dans l'UE. Portail : `data.gouv.fr`.
Santé, finance et énergie	Santé : amélioration des **diagnostics**. Finance : **détection des fraudes** et analyse des risques. Énergie : optimisation des **réseaux électriques intelligents**. Le volume mondial double tous les **2 ans**.

Pièges et confusions

⚠ Confondre le Big Data avec une simple évolution technologique alors qu'il s'agit d'une révolution organisationnelle et stratégique.

⚠ Croire que le Big Data est réservé aux GAFAM alors qu'il s'est démocratisé auprès des PME et des administrations.

⚠ Confondre le traitement par lots qui stocke les données et le traitement en temps réel qui analyse les flux dès leur arrivée.

⚠ Limiter le Big Data aux données structurées en oubliant que les données non structurées sont le défi le plus complexe.

⚠ Réduire le Big Data à une question de technologie en oubliant la culture data-driven basée sur les faits.

Sigles et définitions

3V Trois piliers fondamentaux : Volume, Variété et Vélocité.

NoSQL Modèle de bases de données offrant une grande flexibilité pour gérer des données non structurées ou semi-structurées.

Hadoop Plateforme open source conçue pour stocker et traiter des volumes massifs de données sur des clusters de serveurs.

HDFS Hadoop Distributed File System, un système de stockage distribué capable de diviser les fichiers en blocs.

MapReduce Modèle de programmation utilisé pour le traitement de données en parallèle sur plusieurs nœuds de calcul.

YARN Yet Another Resource Negotiator qui gère les ressources et planifie les travaux dans un cluster.

IoT Internet of Things permettant aux objets connectés d'émettre des flux continus de données.

Auto-test

1. Quels sont les trois piliers du Big Data ?
2. Quel composant d'Hadoop gère les métadonnées ?
3. Quel est le délai de doublement du volume mondial de données ?
4. Quel est le taux d'analyse des données par les entreprises ?
5. Quelle est la taille par défaut des blocs sous Hadoop 2 ?

Réponses : **1.** Le Volume, la Variété et la Vélocité. · **2.** Le NameNode. · **3.** 2 ans. · **4.** 12 %. · **5.** 128 Mo.

À compléter par la fiche, le podcast et le quiz du module. Rédigé à partir de la fiche de révision ; seuils et chiffres à la date de la source.