PENSE-BÊTE · TECHNIQUE ET COMMANDES

Guide de conversion de données Debian

07-61 Référence Debian - Conversion de données — source : fiche de révision du module (gemma4, 03/11/2026)

À RETENIR

1. L'outil iconv permet de changer les paramètres linguistiques en utilisant l'option -l pour lister les codages supportés.
2. La gestion des fins de ligne s'effectue via des formats comme LF pour Debian ou CR-LF pour MSDOS/Windows.
3. Le paquet alien permet de transformer des formats étrangers comme rpm ou tgz en paquets deb.

Conversion de données textuelles

Notion	À retenir
Codage des caractères	`iconv` (paquet **libc6**) : `iconv -f enc1 -t enc2 entree.txt > sortie.txt`, `iconv -l` liste les codages ; `recode` (souple) ; `nkf` (japonais).
Fins de ligne, tabulations	**LF** (Debian), **CR-LF** (MSDOS/Windows), **CR** (Macintosh) : `fromdos`, `todos`, `frommac`, `tomac` ; fichiers mixtes : `sed -e '/\r$/!s/$/\r/'` ; tabulations : `col -x`, `expand`.
Éditeurs et extraction	`vim ++enc=latin2`, `emacs` ; `w3m -dump` (web), `catdoc` (MSWord), `antiword` (vers ps), `odt2txt` (OpenDocument).
Mise en évidence, formatage	`highlight` (code vers **HTML**, **RTF**, **LaTeX**), `grc` ; `pandoc` (tout format) ; `asciidoctor`, `hugo` (XML, HTML, sites statiques).

Traitement et manipulation des données XML

Notion	À retenir
Principes et syntaxe	Déclaration : `<?xml version="1.0" encoding="UTF-8"?>`. Utilise des **entités prédéfinies** (`"`, `&`) ; `<` et `>` interdits dans attributs/éléments.
XSLT et DSSSL	Transformation via **XSLT** ou **DSSSL** (norme **ISO/IEC 10179:1996** avec `openjade`). **XSL-FO** et `fop` pour le formatage d'objets.
Extraction et analyse	Conversion : `man2html` (manuel), `doclifter` (troff), `wp2x` (WordPerfect **5.0/5.1**). Vérification : `xmllint` (syntaxe XML), `tidy` (HTML), `linklint` (liens).

Composition et typographie

Notion	À retenir
Systèmes roff/groff	Utilisation pour pages de manuel ; macros `-me`, `-ms`, `-mm`, `-man` ; sortie texte brut via `groff -Tascii -me -`.
TeX et LaTeX	Standard `TeX` (Knuth) ; `LaTeX` (Lamport) pour haut niveau ; distribution `TeX Live` ; éditeurs `Lyx` ou `GNU TeXmacs`.
Pages de manuel	Conversion : `docbook-to-man` (SGML vers roff man), `help2man` (via `--help`), `info2man`, `txt2man` ; impression via `man -Tps` et `lpr`.

Gestion des données imprimables

Notion	À retenir
Ghostscript et PDF	Interpréteur **GPL Ghostscript PostScript/PDF** (paquet `ghostscript`) génère une image tramée ; `ghostscript-x` pour l'affichage **X** ; `libpoppler162` pour le rendu PDF ; `poppler-data` pour les **CMaps** (caractères CJK Adobe-*).
Fusion PS/PDF	Fusion via `gs(1)` : dispositif `pswrite` pour **PostScript** (`bla.ps`) et `pdfwrite` pour **PDF** (`bla.pdf`) ; `psmerge(1)` (paquet `psutils`) pour PostScript et `pdftk(1)` (paquet `pdftk`) pour PDF.
Conversion et impression	Conversion : `poppler-utils` (`pdftops`, `pdfinfo`, etc.), `enscript` (ASCII vers PostScript, HTML, RTF, Pretty-Print), `a2ps` (vers PostScript), `pdftk` (PDF) et `html2ps` (HTML vers PostScript) ; Impression : `lp(1)` ou `lpr(1)` (ex. 3 copies triées : option `Collate=True`).

Conversion des courriers électroniques

Notion	À retenir
Encodages MIME	SMTP : données sur **sept bits**. MIME : gère binaire ou **huit bits**. Langues européennes (**ISO-8859-1** ou **UTF-8**) : `quoted-printable`. Japonais (**ISO-2022-JP**) : **sept bits** ; **UTF-8** : `Base64`.
Formats et outils	Standard : **mbox** (**RFC2822**). Conversion vers mbox : `mutt`. Éclatement : `procmail(1)` ou `formail(1)`. MIME : `munpack(1)` / `mpack(1)`. Conversion : `uuencode(1)` / `uudecode(1)`. `uudeview` : encode/décode **BASE64**, **xxencode**, **quoted printable**, **BinHex**.

Résumé de la manipulation de données graphiques

Notion	À retenir
Interface graphique	Manipulation bitmap avec **GIMP** ; gestion/visualisation photos : **Gthumb**, **Geeqie**, **Shotwell** (GNOME) ou **Gwenview**, **Digikam** (KDE) ; vectoriel : **Inkscape** (SVG), **Dia**.
Ligne de commande	Scripts : **Imagemagick**, **Graphicsmagick** ; conversion : **Netpbm**, **Libheif-examples** (HEIF vers `JPEG`, `PNG`, `Y4M`), **Icoutils** (PNG/ICO), **Pstoedit** (PostScript/PDF vers SVG) ; optimisation : **Jpegoptim**, **Optipng**, **Pngquant**.
Métadonnées et OCR	EXIF/IPTC : **Exif**, **Exiv2**, **Exiftran** ; lecture balises : **Exiftags**, **Exifprobe** ; OCR (image vers texte) : **Tesseract-ocr**, **Ocrad**, **Gocr** ; post-traitement : **Unpaper**.

Diverses conversions de données

Notion	À retenir
Conversion de paquets logiciels	Paquet `alien` : transforme formats étrangers (**rpm** ou **tgz**) en paquets **deb**. Extraction RPM : `rpm2cpio` suivi de `cpio --extract`.
Gestion des livres numériques	`calibre` : convertit tout format vers **EPUB** et gère la bibliothèque. `freepwing` : convertit **EB** vers **JIS X 4081** (sous-ensemble d'**EPWING V1**).

Pièges et confusions

- ⚠ Confondre le jeu de caractères et le codage des caractères pour les formats complexes comme l'Unicode.
- ⚠ Utiliser todos pour unifier des fichiers mixtes au lieu de sed pour éviter l'ajout systématique d'un retour charriot.
- ⚠ Utiliser directement les caractères inférieur à et esperluette dans les attributs ou les éléments XML.
- ⚠ Privilégier shift-JIS au lieu de CP932 lors de la conversion de programmes C ou d'URL japonais.
- ⚠ Utiliser ISO-2022-JP au lieu de Base64 pour des données de courriel japonais déjà codées en UTF-8.

Sigles et définitions

ASCII Code sur sept bits sans caractère accentué.

UTF-8 Norme actuelle multi-langues utilisée pour tous les systèmes d'exploitation modernes.

EOL Fin de ligne, dont le format dépend de la plateforme.

XML Extensible Markup Language, langage de balisage de documents dont les informations sont structurées.

XSLT Extensible Stylesheet Language Transformations, utilisé pour convertir un fichier XML vers n'importe quel format.

MIME Multipurpose Internet Mail Extensions, utilisé pour coder les données binaires et textuelles sur huit bits en un format sur sept bits.

SVG Scalable Vector Graphics, format de données graphiques vectorielles.

Auto-test

1. Quel outil permet de lister les codages supportés ?
2. Quel format de fin de ligne est utilisé par Debian ?
3. Quel outil est recommandé pour unifier les styles vers MSDOS sans ajouter de caractères indésirables ?
4. Quel paquet transforme les formats rpm ou tgz en paquets deb ?
5. Quel outil permet de convertir le texte web via l'extraction ?

Réponses : **1.** iconv -l · **2.** LF · **3.** sed · **4.** alien · **5.** w3m -dump

Complément+ : connaissance standard ajoutée, absente de la fiche. À compléter par la fiche, le podcast et le quiz du module. Rédigé à partir de la fiche de révision ; seuils et chiffres à la date de la source.